

## 1.7. ФОРМАЛНИ ЕЗИЦИ. ФОРМАЛНИ ГРАМАТИКИ

### 1. Формални езици - определение.

*Формален език* над азбуката  $\Sigma$  е всяко подмножество  $L$  на  $\Sigma^*$  ( $L \subseteq \Sigma^*$ ). Множеството  $\Sigma^*$  е език над  $\Sigma$ .  $\emptyset$  е език над азбуката  $\Sigma$ , който се нарича празен език. Празният език се различава от езика  $L = \{\Lambda\}$ , който се състои от празната дума  $\Lambda$ .

*Сечение (обединение)* на езиците  $L_1$  и  $L_2$  над азбуката  $\Sigma$  е език  $L = L_1 \cap L_2$  ( $L = L_1 \cup L_2$ ), където  $L_1$  и  $L_2$  са множество от думи над азбуката  $\Sigma$ .

*Произведение на езиците*  $L_1$  и  $L_2$  е език

$$L = L_1 L_2 = \{u \in \Sigma^* \mid u = vw, v \in L_1, w \in L_2\},$$

т.е. множество от всички думи, което се представя като конкатенация между думите на  $L_1$  и  $L_2$ .

Свойства:  $L_1 L_2 \neq L_2 L_1$ ;  $L_1 (L_2 L_3) = (L_1 L_2) L_3$ .

*n-та степен на език:*  $L^n = \underbrace{L L \dots L}_{n\text{-пъти}}$ , като  $L^0 = \{\varepsilon\}$ .

*Итерация на L:*  $L^* = \bigcup_{n \geq 0} L^n$ ;

*Положителна итерация на L:*  $L^+ = \bigcup_{n > 0} L^n$ .

Пример:

Над азбука  $\Sigma = \{0, 1, 2, a, b\}$  се дефинират езиците  $L_1 = \{\varepsilon, 01, a1\}$  и  $L_2 = \{\varepsilon, 02, 1b\}$ , тогава

$$L_1 \cap L_2 = \{\varepsilon\};$$

$$L_1 \cup L_2 = \{\varepsilon, 01, a1, 02, 1b\};$$

$$L_1 L_2 = \{\varepsilon, 01, a1, 02, 1b, 0102, 011b, a102, a11b\}.$$

Пример:

Азбука:  $\Sigma = \{a, b, c\}$ :

$$L_1 = \left\{ \underbrace{\Lambda, a, ab, aab, bc, abc}_{6 \text{ думи}} \right\} - \text{краен език (броят на елементите е краен);}$$

$L_2 = \{a^n | n \geq 0\}$  - безкраен език (броят на елементите е безкраен).

Ако  $L_1 \subseteq L_2$  то

- $L_1$  е подезик на  $L_2$  (езикова съвместимост нагоре);
- $L_2$  е подезик на  $L_1$  (езикова съвместимост надолу);
- ако думите в двата езика съвпадат, т.е. множествата от низове съвпадат: ( $L_1 = L_2$ ), то съществува езикова съвместимост.

Описание на езиците:

- чрез изреждане (при малка мощност на множеството от думи (езика)  $|L|$ );
- чрез правила на образуване (при голяма мощност на множеството от думи (езика)  $|L|$  или при безкрайни езици).

За всички езици броят на правилата, по които се извършва описанието на елементите на езика е краен.

Формалните езици се описват с генерираща формална граматика.

## 2. Формална пораждаща граматика - определение

Формалната пораждаща граматика е наредена четворка

$$G = \{\Sigma, N, S, P\},$$

където  $\Sigma$  е крайното множество (азбука) от *терминални* символи ( $\Sigma \in L$  - запазени думи или символи над езика  $L$ );  $N$  – крайното (непразно) множество (азбука) от *нетерминалните символи* ( $N \notin L$  - символи, подлежащи на дефиниране чрез синтаксиса на езика), наречени *променливи*;  $S$  – началният символ (променлива) на граматиката ( $S \in N$ );  $P$  – крайно множество от *правила* от вида  $\alpha \rightarrow \beta$  (продукции) за пораждане на елементи (думи от езика) - наредени двойки  $(\alpha\beta)$ , за които  $\alpha, \beta \in (\Sigma \cup N)^*$ .

Свойства:

- $\Sigma \cap N = \emptyset$ , т.е.  $\Sigma$  и  $N$  нямат общи символи;
- $\Sigma \cup N = D$  - обединението от множествата от терминални и нетерминални символи - речникът на езика;
- $\alpha \in (D)^+ = (\Sigma \cup N)^+ = (\Sigma \cup N)^* \setminus \{\Lambda\}$  - множеството от всички думи над  $D$  без празния низ ( $\alpha$  има поне един нетерминален символ);
- $\beta \in (\Sigma \cup N)^*$  - множеството от всички думи (низове), образувани над азбуката.

Следователно липсват продукции от вида  $\{\Lambda\} \rightarrow \beta$  и  $\alpha \rightarrow \{\Lambda\}$ .

За група от правила  $\alpha \rightarrow \beta$ ,  $\alpha \rightarrow \gamma$ ,  $\alpha \rightarrow \delta, \dots, \alpha \rightarrow k$  се използва означението  $\alpha \rightarrow \beta | \gamma | \delta | \dots | k$ .

Формалната граматика  $G$  генерира дума  $w \in \Sigma^*$  над езика  $L$ , ако съществува крайна редица от думи:

$$w_0 \rightarrow w_1 \rightarrow w_2 \rightarrow \dots \rightarrow w_n | n \geq 1.$$

Този израз дефинира *изводът* на думата  $w_n = w$  от началния символ  $w_0 = S$ . Ако в  $P$  има правило  $\alpha \rightarrow \beta$ , то думата  $w_{i+1} = \alpha_1 \beta \alpha_2$  се получава от всяка поддума от вида  $w_i = \alpha_1 \alpha \alpha_2$ , като  $\alpha$  се замени с  $\beta$ . Броят на непосредствени изводи  $w_i \rightarrow w_{i+1}$  определя *дължината на извода* на  $w_1 \rightarrow w_n$ .

Множеството от всички думи  $w$  над  $\Sigma$ , за които  $S \rightarrow w$ , се нарича формален език  $L(G)$  над  $\Sigma$ , породен от граматиката  $G$ . Граматиките  $G_1$  и  $G_2$  са еквивалентни, ако  $L(G_1) = L(G_2)$ .

Пример:

1. Нека  $G_1 = \{\Sigma, N, S, P\}$  е пораждаща граматика, където  $\Sigma = \{a, b\}$ ,  $N = \{S, A, B\}$ ,  $S$  – началният символ;  $P$  се състои от правилата:  
 $S \rightarrow A|B$ ;  
 $A \rightarrow aA|a$ ;  
 $B \rightarrow bB|b$ .

$G_1$  поражда всички думи от вида  $\alpha = a^n, n \geq 1$  или  $\beta = b^n, n \geq 1$  от формалния език  $L(G_1)$  след прилагане един път на правило  $S \rightarrow A|B$  и  $n-1$  пъти правило  $A \rightarrow aA|a$  или  $B \rightarrow bB|b$ , т.е.

$$L(G_1) = \{a^n | n \geq 1\} \cup L(G_1) = \{b^n | n \geq 1\}.$$

2. Нека  $G_2 = \{\Sigma, N, S, P\}$  е пораждаща граматика, където  $\Sigma = \{a, b\}$ ,  $N = \{S, A, B\}$ ,  $S$  – началният символ;  $P$  се състои от правилото:  
 $S \rightarrow aA|bB|a|b$ ,  $A \rightarrow aA|a$ ,  $B \rightarrow bB|b$ .

$G_2$  поражда всички думи от вида  $\alpha = a^n, n \geq 1$  или  $\beta = b^n, n \geq 1$ , т.е.

$$L(G_2) = \{a^n | n \geq 1\} \cup L(G_2) = \{b^n | n \geq 1\}.$$

Следователно  $G_1$  и  $G_2$  са еквивалентни, т.е.  $L(G_1) = L(G_2)$ .

3. Нека  $G_3 = \{\Sigma, N, S, P\}$  е пораждаща граматика, където  $\Sigma = \{a, b\}$ ,  $N = \{S\}$ ,  $S$  – началният символ;  $P$  се състои от правилата:  
 $S \rightarrow aSb|ab$ .

$G_3$  генерира думата  $a^3b^3$  в съответствие с извода:

$$S \rightarrow aSb \rightarrow aaSbb \rightarrow aaabbb,$$

където два пъти се прилага правилото  $S \rightarrow aSb$  и един път правилото  $S \rightarrow ab$ .

В общия случай граматиката  $G_3$  генерира езика

$$L(G_3) = \{a^n b^n | n \geq 1\}.$$

### 3. Класификация на пораждащите граматиките по Чомски

В съответствие със структурата на правилата граматиките се подразделят на:

- Граматика – **общ вид – тип 0**:

Правило:  $\alpha A \beta \rightarrow w$ ,  $\alpha, \beta, w \in (\Sigma \cup N)^*$ ,  $A \in N$ .

- Граматика – **контекстна – тип 1**:

Правило:  $\alpha A \beta \rightarrow \alpha w \beta$ ,  $w \neq \varepsilon$ ,  $\alpha, \beta, w \in (\Sigma \cup N)^*$ ,  $A \in N$ :  $A$  може да се замени с  $w$  само ако съществува контекст  $\alpha - \beta$ , където  $\alpha$  е ляв контекст, а  $\beta$  десен контекст на  $A$ .

Тъй като  $|\alpha w \beta| \geq 1$ , то празната дума не се поражда в тази граматика. При необходимост се добавя правилото  $S \rightarrow \varepsilon$ , като получената граматика отново е контекстна. Правилото  $S \rightarrow \varepsilon$  се прилага еднократно и не влияе върху останалите думи, различни от  $\Lambda$  и породени от граматиката.

Пример:

Граматиката  $G_4 = \langle \{a, b, c\}, \{S, A, C\}, S, P \rangle$  с множество от правила от вида  $P = \{S \rightarrow aSAC | abc, S \rightarrow abC, CA \rightarrow BA, BA \rightarrow BC, BC \rightarrow AC, bA \rightarrow bb, C \rightarrow c\}$  е контекстна и поражда език

$$L(G_4) = \{a^n b^n c^n | n \geq 1\}$$

след прилагане  $n-1$  пъти първото правило, един път - второто правило, третото, четвъртото и петото правило в посочената последователност,  $n-1$  пъти правила – шестото правило,  $n$  пъти седмото правило.

Същият език се генерира от  $G_4$  и с множеството от правила от вида  $P = \{S \rightarrow aSAC | abc, cA \rightarrow Ac, bA \rightarrow bb, C \rightarrow c\}$

- Граматика – **безконтекстна – тип 2**:

Правило:  $A \rightarrow w$ ,  $w \in (\Sigma \cup N)^+$ ,  $A \in N$ . Добавя се правилото  $S \rightarrow \varepsilon$  за пораждане на празната дума  $\Lambda$ .

Пример:

Граматиката  $G_5 = \langle \{a, b\}, \{S, A, B\}, S, P \rangle$  с множество от правила от вида

$P = \{S \rightarrow AB, A \rightarrow aA|a, B \rightarrow bB|b\}$  е безконтекстна и поражда език  
 $L(G_5) = \{a^n b^m | n, m \geq 1\}$ .

- Граматика – **автоматна – тип 3:**

Правило:  $A \rightarrow aB|a$ ,  $a \in \Sigma$ ,  $A, B \in N$ . Добавя се правилото  $S \rightarrow \varepsilon$  за пораждаване на празната дума  $\Lambda$ .

Пример:

Граматиката  $G_6 = \langle \{a, b\}, \{S, A, B\}, S, P \rangle$  с множество от правила от вида  
 $P = \{S \rightarrow aA|bB|a|b, A \rightarrow aA|a, B \rightarrow bB|b, S \rightarrow \varepsilon\}$  е автоматна и поражда език  
 $L(G_6) = \{a^n | n \geq 0\} \cup \{b^n | n \geq 0\}$ .

Всяка автоматна граматика е безконтекстна, всяка безконтекстна граматика е контекстна, всяка контекстна граматика е граматика от общ вид, т.е.  $\{G - \text{тип 3}\} \subset \{G - \text{тип 2}\} \subset \{G - \text{тип 1}\} \subset \{G - \text{тип 0}\}$ . Тези включвания се наричат йерархия на Чомски за пораждащите граматики. Езикът, породен от граматика от тип  $i$  ( $i = 0, 1, 2, 3$ ) се нарича език от тип  $i$ , съответно за  $i = 0, 1, 2, 3$  - език от общ вид, контекстен, безконтекстен, автоматен. Породените езици образуват йерархия на Чомски.

#### 4. Видове продукции

В съответствие със структурата на рекурсивната продукция се дефинират следните видове продукции:

- Двойно рекурсивна продукция:

$x \rightarrow \alpha x \beta$  ( $x$  се получава от себе си, като  $\alpha \beta$  са низове);

- Ляво рекурсивна продукция:

$x \rightarrow x \beta$  ( $x$  се получава чрез добавяне на низ отдясно).

- Дясно рекурсивна продукция:

$x \rightarrow \alpha x$  ( $x$  се получава чрез добавяне на низ отляво).

В зависимост от предназначението си продукциите се подразделят на следните видове:

Лексика: правила на множеството  $P$  за пораждаване на думи;

Синтаксис: правила на множеството  $P$  за пораждаване на изрази;

Семантика: допълнителни правила, свързани със смисъла на породените думи или изрази.

## ФОРМАЛНИ ГРАМАТИКИ

Пример:

Дадена е азбуката  $\Sigma = \{a, b, c\}$ . Да се съставят граматики, които пораждаят езиците

1.  $L = \{a^i b^i c^i \mid i \geq 1\}$ ;
2.  $L = \{a^i b^k c^k \mid i, k \geq 1\}$ ;
3.  $L = \{a^i b^k c^l \mid i, k, l \geq 1\}$ .

### 1. Контекстна граматика

За езика  $L = \{a^i b^i c^i \mid i \geq 1\}$  се дефинира граматиката  $G$ . Въвежда се азбука на терминалните символи  $\Sigma = \{a, b, c\}$  и азбука на нетерминалните символи  $N$  с нетерминалните символи  $S, B, C$ , където  $S$  е началният символ. Множество от правила  $P$ :

$$P_1 : S \rightarrow aSBC \xrightarrow{i-1} a^{i-1}S(BC)^{i-1}$$

Например при  $i = 4$ :  $S \rightarrow aSBC \rightarrow a^3S(BC)^3$

$$P_2 : S \rightarrow abC \xrightarrow{1} a^i bC(BC)^{i-1} = a^i bCBC(BC)^{i-2}$$

$$P_3 : CB \rightarrow BC \xrightarrow{(i-1) \text{ пъти}} a^i bBCC(BC)^{i-2} = a^i bBCCBC(BC)^{i-3} = a^i bB^{i-1}C^i$$

$$P_4 : bB \rightarrow bb \xrightarrow{i-1} a^i b^i C^i = a^i b^i C^i$$

$$P_5 : C \rightarrow c \xrightarrow{i \text{ пъти}} a^i b^i c^i$$

Следователно контекстната граматика  $G$  поражда езика  $L = \{a^i b^i c^i \mid i \geq 1\}$ .

### 2. Безконтекстна граматика

За езика  $L = \{a^i b^k c^k \mid i, k \geq 1\}$  се дефинира граматиката

$$G = \langle \{S, A\}, \{a, b, c\}, S = \{S\}, P \rangle$$

с множество от правила  $P$ :

$$P_1 : S \rightarrow aS \xrightarrow{i-1} a^{i-1} S;$$

$$P_2 : S \rightarrow aA \xrightarrow{1} a^1 A;$$

$$P_3 : A \rightarrow bAc \xrightarrow{k-1} a^i b^{k-1} A c^{k-1};$$

$$P_4 : A \rightarrow bc \xrightarrow{1} a^i b^k c^k.$$

Следователно граматиката  $G$  поражда езика  $L = \{a^i b^k c^k \mid i, k \geq 1\}$ .

### 3. Регулярна автоматна граматика

За езика  $L = \{a^i b^k c^l \mid i, k, l \geq 1\}$  се дефинира граматиката

$$G = \langle \{S, A, B\}, \{a, b, c\}, S = \{S\}, P \rangle$$

с множество от правила  $P$ :

$$P_1 : S \rightarrow aS \xrightarrow{i-1} a^{i-1} S;$$

$$P_2 : S \rightarrow aA \xrightarrow{1} a^1 A;$$

$$P_3 : A \rightarrow bA \xrightarrow{k-1} a^{i-1} b^{k-1} A;$$

$$P_4 : A \rightarrow bB \xrightarrow{1} a^i b^k B;$$

$$P_5 : B \rightarrow cB \xrightarrow{l-1} a^i b^k c^{l-1} B;$$

$$P_6 : B \rightarrow c \xrightarrow{1} a^i b^k c^l.$$

Следователно автоматната граматика поражда езика  $L = \{a^i b^k c^l \mid i, k, l \geq 1\}$ .